

BÁO CÁO LAB DAY 10

Data Pipeline & Data Observability cho hệ thống RAG

Thông tin	Chi tiết
Sinh viên	Đặng Thị Thu Thảo
Mã sinh viên	2A202600685
Ngày thực hiện	10/06/2026
Model LLM	GPT-4o-mini (OpenAI)
Embedding model	sentence-transformers/all-MiniLM-L6-v2 (384 chiều)
Vector store	ChromaDB (persistent, cosine similarity)
Nguồn dữ liệu	Crossref REST API — 24 papers

1. Tổng quan

Lab này xây dựng một ETL pipeline hoàn chỉnh cho hệ thống RAG (Retrieval-Augmented Generation) trên dữ liệu bài báo học thuật. Mục tiêu chính là **chứng minh nguyên lý Data Observability**: chất lượng dữ liệu ảnh hưởng trực tiếp đến hiệu suất của agent, và việc giám sát cùng sửa chữa dữ liệu có thể phục hồi hoàn toàn performance mà không cần thay đổi model.

Pipeline được chia làm 2 pha:

- **Phase 1 (Baseline)**: Thu thập → làm sạch → embed → evaluate → report
- **Phase 2 (Corruption)**: Corrupt → evaluate → repair → compare

2. Phase 1 — Baseline Pipeline

2.1. Thu thập dữ liệu (crossref.py)

Dữ liệu được lấy từ Crossref REST API — nguồn metadata bài báo học thuật mở.

- **Endpoint**: <https://api.crossref.org/works>
- **Query**: agentic retrieval augmented generation large language model
- **Filter**: from-pub-date:2025-12-12, has-abstract:true
- **Số records**: 24 papers

Mỗi PaperRecord gồm: paper_id (DOI), title, summary (abstract), authors, categories, published, updated, abs_url, pdf_url, comment (journal name). Raw response được lưu tại **data/raw/** để có thể replay mà không cần gọi lại API.

2.2. Làm sạch dữ liệu (cleaning.py)

Bước	Mô tả
Strip XML tags	Loại bỏ JATS tags (<jats:p>, <jats:italic>...) trong abstract từ Crossref
Normalize whitespace	Chuẩn hóa toàn bộ text fields
Filter invalid	Bỏ record thiếu paper_id hoặc title
Tính age_days	Số ngày từ ngày published đến ngày chạy pipeline
Helper columns	authors_joined, categories_joined, summary_chars
text_for_embedding	Ghép Title + Authors + Categories + Published + Abstract + Journal
Deduplication	Drop duplicate theo paper_id
Sort	Mới nhất lên đầu (sort by published descending)

Kết quả: **24 records sạch**, lưu tại data/clean/papers_clean.csv.

2.3. Embedding, Vector Store và Evaluation Set

Mỗi paper được embed cột text_for_embedding thành vector 384 chiều bằng all-MiniLM-L6-v2, nạp vào ChromaDB collection với cosine similarity. Khi query, câu hỏi được embed và tìm top-k paper gần nhất.

Từ 24 papers, sinh 24 câu hỏi đánh giá thuộc 4 loại — summary, authors, date, categories — mỗi sample có ground_truth_doc_ids để đánh giá retrieval hit/miss.

2.4. Kết quả Evaluation (Baseline)

Metric	Giá trị	Ý nghĩa
Retrieval hit rate	100.0%	Mọi câu hỏi đều retrieve đúng paper
Mean token F1	0.862	Câu trả lời khớp 86.2% từ với ground truth
Judge accuracy	70.8%	GPT-4o-mini đánh giá 70.8% câu trả lời đúng
Mean judge score	4.33 / 5	Điểm trung bình khá cao

2.5. Data Quality & Freshness (Baseline)

6/6 quality checks PASS:

Check	Kết quả	Chi tiết
row_count_min_5	PASS	row_count = 24
paper_id_not_null	PASS	0 null
paper_id_unique	PASS	0 duplicate
title_not_null	PASS	0 null/empty
summary_length_ok	PASS	chỉ 1 row ngắn (4.2%)
freshness_ok	PASS	0 stale rows (ngưỡng 180 ngày)

Freshness: Latest paper: 2026-06-02 · Oldest: 2025-12-19 · is_fresh = True

3. Phase 2 — Corruption Flow

3.1. Các loại Corruption (corruption.py)

Simulate các tình huống data corruption thực tế để đo impact lên RAG agent, sau đó chứng minh repair có thể phục hồi performance.

Loại	Rows affected	Tác động
Drop latest records	-3 rows	Agent mất kiến thức về papers gần đây nhất
Blank summary	3 rows	text_for_embedding mất nội dung chính → embedding sai
Inject noise	2 rows	Chuỗi random thêm vào abstract → embedding bị nhiễu
Truncate title	2 rows	Title bị cắt còn 15 ký tự → lookup by title thất bại
Stale published date	2 rows	Published year lùi 2 năm → freshness alarm
Add duplicates	+1 row	paper_id_unique check FAIL → bias ranking

Kết quả: 24 rows → 22 rows sau corruption.

3.2. Kết quả sau Corruption

Metric	Baseline	Corrupted	Δ
Retrieval hit rate	100.0%	87.5%	-12.5%
Mean token F1	0.862	0.717	-0.145
Judge accuracy	70.8%	70.8%	0%
Mean judge score	4.333	4.125	-0.208
Quality checks	6/6 PASS	5/6 (1 FAIL)	paper_id_unique FAIL
Stale rows	0	2	+2

Chỉ 6 thao tác nhỏ đã làm **Retrieval Hit Rate giảm 12.5%** và Token F1 giảm 14.5%. Agent trả lời sai 3/24 câu hỏi — những câu liên quan đến papers bị drop hoặc abstract bị xóa.


3.3. Repair và kết quả phục hồi

Thay vì gọi lại API, pipeline re-clean trực tiếp từ data/raw/crossref_records.json: load_raw_records() → build_clean_dataframe() → LocalEmbeddingIndex.build().


Metric	Baseline	Corrupted	Repaired	Recovery
Retrieval hit rate	100.0%	87.5%	100.0%	Full
Mean token F1	0.862	0.717	0.862	Full
Judge accuracy	70.8%	70.8%	70.8%	Same
Mean judge score	4.333	4.125	4.333	Full
Quality checks	6/6	5/6	6/6	Full
Stale rows	0	2	0	Full

Tất cả metrics phục hồi hoàn toàn mà không cần thay đổi model hay re-fetch API.

4. Visualization — So sánh 3 trạng thái



Hình 1. So sánh evaluation metrics: Baseline / Corrupted / Repaired



Hình 2. Data quality checks và freshness qua 3 trạng thái dữ liệu

4.1. Freshness chi tiết

Field	Baseline	Corrupted	Repaired
latest_published	2026-06-02	2026-05-06	2026-06-02
oldest_published	2025-12-19	2024-02-26	2025-12-19
stale_rows	0	2	0
total_rows	24	22	24
is_fresh	True	True	True

5. Kết luận

Nguyên lý Data Observability được chứng minh: **“Không phải model kém — mà là data xấu.”**

- Data quality → RAG quality:** chỉ 3 papers bị drop + 3 abstract bị blank đã làm hệ thống mất 12.5% khả năng tìm đúng tài liệu. Agent không “biết” mình đang dùng data xấu.
- Monitor early, fix fast:** quality checks phát hiện ngay paper_id_unique FAIL và stale dates — đây là signal để trigger repair trước khi user nhận ra agent trả lời sai.
- Raw source là source of truth:** repair từ raw records (không cần re-fetch API) khôi phục hoàn toàn mọi metrics — nhấn mạnh tầm quan trọng của việc lưu trữ raw data.
- Data Observability > Model tuning:** fix data nhanh hơn và hiệu quả hơn nhiều so với fine-tune hay thay đổi model.

5.1. Artifacts đầu ra

File	Mô tả
data/raw/crossref_response.json + crossref_records.json	Raw API response và parsed records
data/clean/papers_clean*.csv/json	Dataset baseline / corrupted / repaired
data/eval/test_set.json	24 câu hỏi evaluation
data/results/*_metrics.json, *_answers.json	Metrics và answers cho 3 trạng thái
data/results/corruption_log.json	Log các thao tác corruption
data/quality/*_quality.json, *_freshness.json	Quality checks và freshness reports
data/reports/phase1_report.md, corruption_report.md	Báo cáo markdown tự sinh từ pipeline
app.py, app2.py	Streamlit dashboard giám sát